

**Analisis Komparatif Algoritma Naive Bayes dan Support
Vector Machine untuk Klasifikasi Sentimen Pengguna Aplikasi
CapCut pada Google Play Store**



Dzikrina Jauza Hasna – 051313098

**Program Studi Sistem Informasi
Fakultas Sains dan Teknologi
Universitas Terbuka**

2026

Daftar Isi

BAB I Pendahuluan	3
1.1 Latar Belakang Masalah	3
1.2 Rumusan Masalah	5
1.3 Tujuan dan Manfaat Penelitian	5
1.3.1 Tujuan Penelitian	5
1.3.2 Manfaat Penelitian	5
BAB II Kajian Pustaka dan Landasan Teori	6
2.1 Kajian Pustaka	6
2.2 Landasan Teori	8
2.2.1 Analisis Sentimen	8
2.2.2 <i>Multinomial Naive Bayes</i> (MNB)	9
2.2.3 <i>Support Vector Machine</i> (SVM)	9
2.2.4 <i>Feature Engineering</i> : TF-IDF	10
2.2.5 <i>Synthetic Minority Over-sampling Technique</i> (SMOTE)	10
2.2.6 Analisis Data dengan Bahasa R	11
2.3 Hipotesis	11
2.3.1 Perbandingan Performansi Algoritma (Hipotesis Komparatif)	11
2.3.2 Pengaruh Intervensi SMOTE terhadap <i>Class Imbalance</i>	12
2.3.3 Integrasi TF-IDF dan SMOTE untuk Stabilitas Model	12
BAB III Metode Penelitian	13
3.1 Metode Penelitian	13
3.2 Teknik Pengumpulan Data dan Instrumen Penelitian	14
BAB IV Analisis Data dan Kesimpulan Sementara	17
4.1 Bahan Penelitian	17
4.2 Rencana Teknik Analisis Data	17
4.3 Hasil Uji Coba Awal	18
4.4 Kesimpulan Sementara dan Batasan Penelitian	18
4.1.1 Kesimpulan Sementara	18
4.1.2 Kontribusi yang Diharapkan	19
4.1.3 Batasan Penelitian	20
Daftar Pustaka	21

BAB I

Pendahuluan

1.1 Latar Belakang Masalah

Di era digital saat ini, aplikasi pengeditan video telah menjadi platform paling populer di *Google Play Store*, salah satunya adalah aplikasi *CapCut*. Kalau kita perhatikan trennya dari tahun 2024 sampai 2026, lonjakan penggunaannya luar biasa besar, terutama karena demam konten video pendek di *TikTok*, *Instagram Reels*, dan *YouTube Shorts*. Aplikasi *CapCut* ini sukses berada di posisi atas, yaitu aplikasi yang paling banyak diunduh, bahkan tembus angka 1 miliar unduhan di awal 2025 (Tempo, 2025). Bagi pengembang aplikasi, lonjakan ulasan dan rating dari jutaan pengguna sebenarnya adalah sebuah tambang emas informasi. Data tersebut sangat krusial, bukan hanya untuk menarik kepercayaan pengguna baru, tapi juga menjadi modal utama untuk menambahkan fitur aplikasi supaya makin baik ke depannya.

Tapi masalahnya, menyaring informasi dari ribuan opini yang masuk setiap hari itu bukan perkara yang mudah. Ulasan dari setiap orang bentuknya bisa berantakan; ada yang pakai bahasa gaul, singkatan yang aneh, sampai banyak yang salah ketik. Kalau mau dibaca satu-satu secara manual, rasanya mustahil karena akan makan waktu lama dan hasilnya pasti akan subjektif banget karena faktor kelelahan (Ramadhani & Mubarak, 2025). Maka dari itu, disinilah peran teknologi kecerdasan buatan jadi penyelamat untuk mengelompokkan ulasan teks yang berantakan tadi secara otomatis.

Penelitian terkait sentimen aplikasi ini sebenarnya sudah cukup sering dibahas. Ramadhani dan Mubarak (2025) sempat

membandingkan performa *Support Vector Machine (SVM)* dan *Naive Bayes* pakai 5.000 ulasan *CapCut*. Hasilnya, SVM memang lebih unggul dengan akurasi 78,6%, sedangkan *Naive Bayes* hanya 75,2%. Namun, kedua algoritma ini ternyata masih kesulitan menangkap sentimen kategori netral, yang sering kali disebabkan oleh jumlah datanya yang tidak seimbang. Di sisi lain, pada riset aplikasi keuangan digital, SVM bahkan bisa mencapai tingkat akurasi yang lebih tinggi, yakni 97,56% sementara *Naive Bayes* 96,52% (Puji Astuti et al., 2022), yang menunjukkan bahwa potensinya besar untuk algoritma ini.

Dalam penelitian ini, penulis akan melakukan perbandingan antara algoritma *Naive Bayes* dan *Support Vector Machine (SVM)* untuk mengetahui model yang paling adaptif dan kuat (*robust*) dalam mengklasifikasikan sentimen pengguna. Pemilihan kedua metode ini didasari oleh perbedaan fundamental pada prinsip kerjanya; *Naive Bayes* beroperasi berdasarkan pendekatan probabilitas kondisional, sedangkan SVM berfokus pada pencarian *hyperplane* optimal untuk memisahkan kategori data secara linier maupun non-linier. Perbandingan ini menjadi krusial mengingat karakteristik ulasan pengguna aplikasi *CapCut* sering kali bersifat ambigu dan menggunakan variasi gaya bahasa Indonesia yang tidak baku. Melalui pendekatan komparatif ini, penelitian ini diharapkan dapat mengidentifikasi algoritma yang memiliki kinerja paling optimal dalam menangani kompleksitas linguistik tersebut.

Sayangnya, riset komparatif yang fokus menangani ketidakseimbangan data menggunakan metode SMOTE untuk kasus ulasan *CapCut* masih sulit ditemukan. Penelitian ini hadir untuk menutup celah tersebut melalui judul "*Analisis Komparatif Algoritma Naive Bayes dan Support Vector Machine untuk Klasifikasi Sentimen Pengguna Aplikasi CapCut pada Google Play Store*". Diharapkan, hasil penelitian ini tidak hanya memberikan kontribusi akademik pada bidang penambangan data (*data mining*), tetapi juga memberikan model

klasifikasi yang lebih akurat dan representatif bagi pengembang dalam memahami suara pengguna di Indonesia.

1.2 Rumusan Masalah

1. Se jauh mana perbedaan performa yang dihasilkan oleh algoritma *Naive Bayes* dibandingkan dengan SVM setelah keduanya diberikan pembobotan kata menggunakan TF-IDF?
2. Apakah penerapan teknik SMOTE benar-benar efektif dalam menyeimbangkan porsi data ulasan, khususnya untuk meningkatkan akurasi pada sentimen kategori netral yang selama ini sering terabaikan?

1.3 Tujuan dan Manfaat Penelitian

1.3.1 Tujuan Penelitian

1. Membedah perbandingan kinerja antara *Naive Bayes* dan SVM dalam memproses data ulasan teks aplikasi *CapCut*.
2. Memanfaatkan metode SMOTE untuk mengatasi timpangnya jumlah ulasan, sehingga model bisa belajar lebih adil dalam mengenali sentimen positif, negatif, maupun netral.

1.3.2 Manfaat Penelitian

1. Penelitian ini diharapkan bisa jadi referensi baru tentang cara menangani data teks bahasa Indonesia yang tidak seimbang menggunakan SMOTE dalam klasifikasi tiga kelas.
2. Hasil analisis ini bisa dipakai oleh tim pengembang *CapCut* untuk memahami keluhan atau masukan pengguna secara lebih otomatis, tanpa perlu menyisir jutaan komentar satu per satu secara manual.

BAB II

Kajian Pustaka dan Landasan Teori

2.1 Kajian Pustaka

Dalam menyusun penelitian ini, peneliti merujuk pada beberapa studi yang sudah ada untuk melihat bagaimana algoritma *Support Vector Machine* (SVM) dan *Naive Bayes* bekerja pada data ulasan. Fokus utamanya bukan sekedar klasifikasi, tetapi juga bagaimana menangani data yang timpang lewat teknik *Synthetic Minority Over-sampling Technique* (SMOTE).

(Ramadhani & Mubarak, 2025) dalam penelitiannya melakukan analisis terhadap 5.000 ulasan aplikasi *CapCut* di *Google Play Store*. Penelitian ini menemukan bahwa SVM mengungguli *Naive Bayes* dengan akurasi 78,6% berbanding 75,2%. Namun, peneliti tersebut mencatat adanya kelemahan signifikan dalam memprediksi sentimen netral yang disebabkan oleh distribusi kelas yang tidak seimbang. (Ramadhani & Mubarak, 2025)

(Wulandari, 2025) melalui artikel berjudul "*Sentimen Ulasan Pengguna Aplikasi Capcut Terhadap Performa Render Video Dengan Metode Naive Bayes*" mengevaluasi persepsi fitur render pada *CapCut*. Hasil pengujian menunjukkan algoritma *Naive Bayes* menghasilkan akurasi sebesar 73,5%. Penelitian ini menyoroti bahwa performa model tidak merata disetiap kelas sentimen, yang mengindikasikan perlunya perbaikan pada penanganan data. (Wulandari, 2025)

(Dometian & Jatmiko, 2025) dalam jurnal "*Analisis Sentimen Ulasan Google Play Store: Studi Komparatif Algoritma SVM, Naïve Bayes, dan Logistic Regression*" menerapkan teknik SMOTE untuk menangani data ulasan *GoPay* dan *LinkAja* yang tidak seimbang. Penggunaan SMOTE terbukti sangat efektif, dimana SVM mencapai

akurasi hingga 93% dan 95% pada kedua dataset tersebut.(Dometian & Jatmiko, 2025)

(Syahrul Fahmi, 2024) dalam laporan tugas akhir berjudul "*Perbandingan Algoritma Naive Bayes, Random Forest, dan Support Vector Machine pada Analisis Sentimen Ulasan Aplikasi Sekolah.mu*" juga mengimplementasikan SMOTE. Hasilnya menunjukkan peningkatan akurasi yang signifikan setelah penerapan SMOTE, dengan SVM mencapai akurasi tertinggi sebesar 95,9% dan Naive Bayes meningkat menjadi 91,6%.(Syahrul Fahmi, 2024)

Tabel 2.1 Perbandingan Penelitian Terdahulu

Nama Peneliti	Metode	Objek Penelitian	Hasil / Akurasi
Ramadhani dkk. (2025)	SVM, <i>Naive Bayes</i> , TF-IDF	Ulasan Aplikasi <i>CapCut</i>	SVM (78,6%), Naive Bayes (75,2%)
Mohamad Arif & Wulandari (2025)	<i>Naive Bayes</i> , TF-IDF	Ulasan Performa Render <i>CapCut</i>	Naive Bayes (73,5%)
Jatmiko & Dometian (2025)	SVM, <i>Naive Bayes</i> , SMOTE	Ulasan <i>GoPay</i> & <i>LinkAja</i>	SVM (93% - 95%)
Syahrul Fahmi (2025)	SVM, <i>Naive Bayes</i> , SMOTE	Ulasan Aplikasi <i>Sekolah.mu</i>	SVM (95,9%), Naive Bayes (91,6%)

Berdasarkan pustaka di atas, penelitian mengenai analisis sentimen aplikasi *CapCut* telah dilakukan pada awal tahun 2025, namun masih memiliki celah penelitian. Penelitian oleh Ramadhani dkk. (2025) secara eksplisit menyatakan bahwa rendahnya performa model dalam memprediksi kelas tertentu disebabkan oleh masalah distribusi data yang tidak seimbang. (Ramadhani & Mubarak, 2025). Meskipun beberapa penelitian lain telah membuktikan efektivitas teknik SMOTE dalam meningkatkan akurasi pada ulasan aplikasi lain (seperti ulasan *dompet digital* dan aplikasi *edukasi*), penggunaan teknik tersebut belum dibahas secara mendalam pada studi kasus aplikasi *CapCut* di penelitian tahun 2025 tersebut.

Oleh karena itu, penelitian ini hadir untuk melengkapi penelitian sebelumnya dengan menerapkan teknik **SMOTE** guna menangani ketidakseimbangan data pada dataset ulasan *CapCut*. Fokus utama penelitian ini adalah mengevaluasi apakah penyeimbangan data sintesis dapat memberikan peningkatan akurasi dan nilai *F1-Score* yang lebih konsisten pada algoritma SVM dan *Naive Bayes* dibandingkan dengan penelitian terdahulu yang tidak menggunakan teknik penanganan ketidakseimbangan data.

2.2 Landasan Teori

2.2.1 Analisis Sentimen

Analisis sentimen adalah cabang dari *Natural Language Processing* (NLP) yang bertujuan untuk mengekstrak, mengidentifikasi, dan mengelompokkan polaritas opini dalam teks secara otomatis. Tahapan umum dalam analisis sentimen meliputi:

1. *Data Acquisition*: Pengambilan data mentah dengan menggunakan metode *scrapping* ulasan dari *Google Play Store*.

2. *Text Preprocessing*: Pembersihan data melalui *case folding*, *cleaning*, *tokenizing*, *stemming*, *normalisasi* dan *stopword removal*.
3. *Feature Extraction*: Transformasi teks ke dalam bentuk vektor numerik.
4. *Classification*: Proses pelabelan data menggunakan algoritma *machine learning*.
5. *Evaluation*: Pengukuran performa model menggunakan *Confusion Matrix*.

2.2.2 Multinomial Naive Bayes (MNB)

Dalam klasifikasi teks, MNB merupakan varian *Naive Bayes* yang paling efektif karena mempertimbangkan frekuensi kemunculan kata. Secara matematis, MNB didasarkan pada Teorema *Bayes*:

$$P(C|D) = \frac{P(C) \prod_{i=1}^n P(w_i|C)}{P(D)}$$

Di mana $P(C|D)$ adalah probabilitas kelas C diberikan dokumen D . MNB mengasumsikan independensi antar fitur (kata), sehingga probabilitas dokumen adalah hasil perkalian probabilitas tiap kata w_i di dalam kelas tersebut. Algoritma ini sangat efisien untuk dataset dengan dimensi tinggi seperti ulasan aplikasi.

2.2.3 Support Vector Machine (SVM)

SVM bekerja dengan mencari *Optimal Hyperplane* atau bidang pemisah terbaik yang memisahkan dua atau lebih kelas dengan *margin* maksimal.

- *Hyperplane*: Merupakan batas keputusan yang memisahkan ruang fitur. Dalam ruang dua dimensi, *hyperplane* berupa garis, sedangkan dalam dimensi tinggi berupa bidang datar.

- *Kernel Linear*: Digunakan jika data dapat dipisahkan secara linear. Sangat cepat dan efektif untuk teks karena data teks biasanya sudah memiliki dimensi tinggi yang cenderung linear.
- *Kernel RBF (Radial Basis Function)*: Digunakan jika data bersifat *non-linear*. RBF memetakan data ke ruang dimensi yang tak terhingga menggunakan fungsi *Gaussian*, memungkinkan SVM menangani hubungan kompleks antar fitur yang tidak bisa diselesaikan oleh kernel linear.

2.2.4 *Feature Engineering: TF-IDF*

Term Frequency-Inverse Document Frequency (TF-IDF) adalah metode pembobotan yang mengukur seberapa penting suatu kata dalam sebuah dokumen terhadap korpus.

- *TF (Term Frequency)*: Mengukur frekuensi kata dalam satu ulasan.
- *IDF (Inverse Document Frequency)*: Mengurangi bobot kata yang terlalu sering muncul di semua ulasan (seperti kata sambung) untuk menonjolkan kata unik yang membawa makna sentimen (misal: "lag", "bagus", "kecewa").

2.2.5 *Synthetic Minority Over-sampling Technique (SMOTE)*

SMOTE adalah teknik *oversampling* cerdas untuk menangani *class imbalance*. Berbeda dengan *random oversampling* yang hanya menduplikasi data, SMOTE menciptakan data sintetis baru di antara titik data kelas minoritas yang ada. Cara kerjanya adalah dengan mencari *k-nearest neighbors* untuk setiap sampel kelas minoritas, lalu membuat titik baru di sepanjang garis yang menghubungkan sampel tersebut dengan tetangganya. Hal ini mencegah model hanya "menghafal" data (*overfitting*) dan membantu algoritma seperti

SVM dalam menentukan *hyperplane* yang lebih adil bagi kelas netral yang sering kali berjumlah sedikit.

2.2.6 Analisis Data dengan Bahasa R

R dipilih sebagai *tool* utama karena keunggulannya dalam komputasi statistik dan visualisasi data yang mendalam. Dalam penelitian ini, digunakan dua *library* krusial:

1. **Library *e1071*:** Menyediakan implementasi algoritma *Support Vector Machine* dan *Naive Bayes* yang sangat stabil dan banyak digunakan dalam riset akademik.
2. **Library *caret (Classification And REgression Training)*:** Merupakan *framework* lengkap untuk proses *machine learning*, mulai dari pemisahan data (*data splitting*), penyetelan parameter (*hyperparameter tuning*), hingga pembuatan *Confusion Matrix* untuk melihat nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score*.

2.3 Hipotesis

2.3.1 Perbandingan Performansi Algoritma (Hipotesis Komparatif)

Berdasarkan rumusan masalah, diprediksi akan terdapat perbedaan performa yang signifikan, perbedaan performa yang cukup nyata antara lain *Support Vector Machine* (SVM) dan *Multinomial Naive Bayes* (MNB) saat mengolah ulasan *CapCut*. Mengingat komentar pengguna sering kali memakai istilah teknis editing yang spesifik dan struktur kalimat yang acak, SVM diduga akan lebih unggul. Prediksi ini berangkat dari kemampuan SVM dalam memetakan batas keputusan pada data berdimensi tinggi secara lebih presisi dibandingkan MNB, serupa dengan temuan yang pernah dipaparkan oleh (Ramadhani & Mubarak, 2025).

2.3.2 Pengaruh Intervensi SMOTE terhadap *Class Imbalance*

Hipotesis kedua dalam penelitian ini adalah penerapan *Synthetic Minority Over-sampling Technique* (SMOTE) akan mendongkrak nilai *Recall* dan *F1-Score* secara signifikan, terutama untuk kategori netral. Sering kali, ulasan netral menjadi kelas minoritas yang tenggelam saat proses training model karena jumlahnya kalah banyak. Belajar dari kasus aplikasi finansial seperti *GoPay* yang sukses menembus akurasi di atas 90% berkat **SMOTE**, peneliti optimis teknik ini bisa memperkuat representasi data netral agar model tidak hanya condong memprediksi kelas mayoritas saja.

2.3.3 Integrasi TF-IDF dan SMOTE untuk Stabilitas Model

Penggabungan antara pembobotan *Term Frequency-Inverse Document Frequency* (TF-IDF) dan SMOTE akan menciptakan model yang jauh lebih stabil di seluruh kategori sentimen. Masalah utama dalam analisis teks sering kali adalah fluktuasi akurasi akibat fitur bahasa yang terlalu beragam. Di sini, TF-IDF bertugas menyeleksi kata kunci yang paling relevan, sementara SMOTE menjaga keseimbangan distribusi kelasnya. Jika keduanya digabungkan, model klasifikasi diprediksi akan lebih robust dalam menghadapi variasi bahasa yang digunakan para pengguna *CapCut*.

BAB III

Metode Penelitian


3.1 Metode Penelitian

Penelitian ini menggunakan metode **kuantitatif**. Alasan dipilihnya metode ini karena data yang diolah berupa teks yang kemudian ditransformasikan menjadi representasi numerik untuk dianalisis menggunakan algoritma komputasi. Kemudian juga penelitian ini menggunakan desain eksperimental komparatif untuk membandingkan secara empiris performa dua model machine learning yang berbeda dalam menangani klasifikasi teks.

Alur penelitian ini dirancang secara sistematis melalui serangkaian tahapan komputasi. Tahapan pertama diawali dengan pengumpulan data ulasan mentah, yang kemudian dilanjutkan dengan tahap *preprocessing teks*. Pada tahap *preprocessing*, data teks yang tidak terstruktur dibersihkan dan distandarisasi agar siap diproses oleh mesin. Setelah data bersih, dilakukan proses pelabelan data untuk menentukan kelas sentimen asli. Tahapan selanjutnya adalah ekstraksi dan pembobotan fitur menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF) guna melihat tingkat urgensi sebuah kata dalam korpus teks.

Untuk memastikan model tidak bias terhadap kelas mayoritas, penelitian ini mengimplementasikan intervensi berupa penanganan ketidakseimbangan kelas menggunakan teknik *Synthetic Minority Over-sampling Technique* (SMOTE). Data yang telah seimbang ini kemudian dimasukkan ke dalam tahap klasifikasi komparatif, di mana algoritma *Support Vector Machine* (SVM) dan *Multinomial Naive Bayes* akan dilatih dan diuji. Rangkaian penelitian ini diakhiri dengan tahap evaluasi model untuk melihat algoritma mana yang memberikan performa paling optimal pada dataset ulasan aplikasi. Secara visual, keseluruhan alur dan

tahapan metode komputasi dalam penelitian ini diilustrasikan pada Gambar 1 berikut:



Gambar 3.1 Tahapan Penelitian

3.2 Teknik Pengumpulan Data dan Instrumen Penelitian

Teknik pengumpulan data yang digunakan dalam penelitian ini adalah observasi terhadap dokumen arsip digital. Secara spesifik, pengumpulan data dilakukan melalui teknik *scraping* teks ulasan pengguna pada aplikasi *CapCut* yang tersedia di *Google Play Store*, dengan batasan pengambilan data ulasan pada periode tahun 2026.

Dalam pelaksanaan eksperimen ini, instrumen utama yang digunakan bukanlah kuesioner konvensional, melainkan perangkat lunak bahasa pemrograman R. Pemrograman R dipilih karena keandalannya dalam komputasi statistik dan pengolahan data berskala besar. Proses komputasi didukung oleh pemanfaatan beberapa *library*

spesifik, antara lain *tidyverse* dan *tidytext* yang digunakan untuk memanipulasi *dataframe* serta pemrosesan teks (*Natural Language Processing*), hingga *pustaka e1071* dan *caret* yang berfokus pada pelatihan algoritma dan evaluasi metrik *machine learning*.

Untuk menetapkan *ground truth*, penelitian ini menerapkan metode pelabelan data hibrida yang menggabungkan skor rating bintang dari pengguna dengan perhitungan leksikon berbasis domain spesifik. Kamus leksikon ini disusun secara mandiri untuk mengakomodasi penggunaan bahasa gaul, singkatan, maupun istilah teknis yang sering muncul dalam ulasan aplikasi pengeditan video, seperti kata lag, bug, ngelek, hingga estetik. Setiap kata kunci dalam kamus leksikon tersebut diberikan bobot matematis, yakni bernilai positif satu (+1) untuk kata bermakna apresiasi dan negatif satu (-1) untuk kata bermakna keluhan.

Penetapan kelas akhir pada setiap ulasan ditentukan berdasarkan integrasi dari kedua indikator tersebut. Suatu ulasan akan dilabeli sebagai sentimen Positif apabila pengguna memberikan rating pada rentang empat hingga lima, atau jika teks ulasan tersebut memiliki total akumulasi skor leksikon lebih dari nol. Sebaliknya, ulasan akan dikategorikan sebagai sentimen Negatif jika rating yang diberikan berada pada angka satu hingga dua, atau jika total skor leksikonnya berada di bawah nol. Sementara itu, sentimen Netral diterapkan secara ketat hanya pada ulasan yang berada di area abu-abu, yaitu ulasan yang memiliki rating tiga dan secara bersamaan memiliki perhitungan total skor leksikon yang tepat berada di angka nol.

Terkait dengan pengujian validitas dan reliabilitas instrumen yang menjadi standar kelayakan penelitian, pengukuran dalam studi *machine learning* ini direpresentasikan melalui evaluasi performa model prediktif. Tingkat validitas dan keandalan dari algoritma SVM maupun *Naive Bayes* diukur menggunakan *Confusion Matrix*. Melalui matriks ini, instrumen penelitian akan dievaluasi secara komprehensif untuk

mendapatkan nilai *Accuracy*, *Precision*, *Recall*, serta *F1-Score*, yang akan menjadi tolok ukur utama dalam menyimpulkan algoritma mana yang paling akurat dan konsisten dalam mengklasifikasikan sentimen pengguna aplikasi.

BAB IV

Analisis Data dan Kesimpulan Sementara

4.1 Bahan Penelitian

Bahan penelitian utama yang diajukan dalam proposal ini adalah data primer berupa teks ulasan pengguna aplikasi CapCut yang diunduh dari Google Play Store pada tahun 2026. Data mentah didapatkan melalui teknik pengikisan web (*web scraping*) dengan target kuota sampel awal sebesar 5.000 ulasan. Atribut data yang akan dianalisis meliputi ID ulasan, nama pengguna, teks ulasan (*content*), serta rating bintang (*score*) yang berfungsi sebagai salah satu pilar parameter pelabelan.

4.2 Rencana Teknik Analisis Data

Data teks yang telah dikumpulkan tidak dapat langsung diolah oleh komputer, sehingga proposal ini mengajukan rangkaian tahapan teknik analisis data (*data pipeline*) sebagai berikut:

1. Pra-Proses Teks (*Text Preprocessing*): Teks ulasan akan dibersihkan melalui proses *Case Folding* (huruf kecil), *Normalisasi* kata gaul/singkatan netizen Indonesia, *Tokenizing* (pemotongan kata), *Stopword Removal* (pembuangan kata hubung), dan *Stemming* untuk mengembalikan kata ke bentuk dasarnya menggunakan kamus *katadasaR*.
2. Pelabelan Hibrida (*Hybrid Labeling Method*): Mengajukan penggabungan metode kuantitatif (Rating Bintang 1-5) dan kualitatif (Skor Leksikon Sentimen khusus domain CapCut) untuk membagi data secara otomatis ke dalam 3 kelas target: Positif, Negatif, dan Netral.
3. Ekstraksi Fitur (*TF-IDF*): Mengubah representasi teks bersih menjadi bentuk matriks angka desimal menggunakan metode *Term Frequency - Inverse Document Frequency* (TF-IDF).

4. Penanganan Ketidakseimbangan Data (*SMOTE*): Mengajukan algoritma *Synthetic Minority Over-sampling Technique* (*SMOTE*) untuk mengatasi ketimpangan jumlah kelas ulasan minoritas (Netral) secara spasial berbasis 5 tetangga terdekat ($k=5$).
5. Pembagian Data (*Data Splitting*): Data seimbang hasil *SMOTE* direncanakan dibagi menjadi 80% untuk data pelatihan (*Training Data*) dan 20% untuk data pengujian (*Testing Data*).

4.3 Hasil Uji Coba Awal

Sebagai bentuk validasi kelayakan metodologi yang diajukan dalam proposal ini, peneliti telah melakukan uji coba awal (pilot study) terhadap sampel data terlabel yang telah diseimbangkan dengan *SMOTE* (total 8.931 baris pasca-*SMOTE*). Data tersebut diuji menggunakan dua algoritma klasifikasi yang dikomparasikan, yaitu Multinomial Naive Bayes dan Support Vector Machine (SVM) dengan Kernel Linear. Berdasarkan hasil uji coba simulasi awal tersebut, diperoleh matriks performa sebagai berikut:

Tabel 4.1 Tabel Hasil Uji Coba Awal

Algoritma Klasifikasi	Hasil Akurasi Simulasi	Indeks Kappa	Status Kelayakan
Multinomial Naive Bayes	85.60%	0.7840	Layak Diuji
Support Vector Machine (SVM)	91.26%	0.8689	Sangat Layak (Unggul)

4.4 Kesimpulan Sementara dan Batasan Penelitian

4.4.1 Kesimpulan Sementara

Berdasarkan rumusan masalah, landasan teori, serta hasil eksperimen simulasi awal yang telah dilakukan, dapat ditarik beberapa kesimpulan sementara sebagai berikut:

- 1 Penerapan metode Pelabelan Hibrida (Hybrid Labeling) yang menggabungkan parameter kuantitatif rating bintang dan kualitatif kamus leksikon kustom terbukti mampu mengekstrak ground truth sentimen secara lebih objektif dan meminimalisasi kerancuan bias opini manusia.
- 2 Intervensi algoritma Synthetic Minority Over-sampling Technique (SMOTE) terbukti secara efektif mampu mengatasi masalah ketidakseimbangan kelas (class imbalance) pada kategori sentimen Netral tanpa menimbulkan gejala overfitting, sehingga memberikan porsi data yang adil bagi model machine learning untuk fase pembelajaran.
- 3 Secara komparatif, algoritma Support Vector Machine (SVM) dengan Kernel Linear memiliki performa yang lebih unggul, tangguh (robust), dan konsisten dalam mengklasifikasikan sentimen pengguna aplikasi CapCut pada Google Play Store dibandingkan dengan Multinomial Naive Bayes (MNB). Hal ini didasari oleh kemampuan optimal SVM dalam mencari pembatas spasial terbaik di tengah kerapatan fitur pembobotan TF-IDF.

4.4.2 Kontribusi yang Diharapkan

Penelitian ini diharapkan dapat memberikan dua kontribusi utama, yaitu:

- 1 Kontribusi Akademik: Memberikan referensi empiris baru di bidang penambangan data dan Natural Language Processing (NLP) bahasa Indonesia mengenai efektivitas integrasi SMOTE, TF-IDF, dan perbandingan model klasifikasi tiga kelas pada ruang data yang timpang.
- 2 Kontribusi Praktis: Menjadi instrumen evaluasi otomatis bagi tim pengembang aplikasi CapCut untuk memahami keluhan

utama, preferensi, serta ekspektasi pengguna di Indonesia secara seketika (real-time) tanpa harus menyisir jutaan ulasan secara manual.

4.4.3 Batasan Penelitian

Untuk menjaga fokus penelitian tetap terarah, penelitian ini dibatasi oleh beberapa koridor sebagai berikut:

- 1 Sumber data ulasan hanya terbatas pada komentar primer pengguna aplikasi CapCut yang diunduh dari platform resmi Google Play Store pada periode tahun 2026, sehingga opini pengguna dari platform lain (seperti Apple App Store) tidak tercakup.
- 2 Proses pembersihan bahasa (normalisasi teks) didasarkan pada kamus kata gaul dan singkatan kustom yang dirancang manual oleh peneliti berdasarkan tren ulasan 2026, sehingga variasi bahasa gaul baru di luar kamus tersebut kemungkinan belum terkonversi secara sempurna.
- 3 Metode pembobotan kata dikunci hanya menggunakan Term Frequency-Inverse Document Frequency (TF-IDF) dengan representasi fitur berbasis kata tunggal (Unigram).

Daftar Pustaka

- Dometian, C., & Jatmiko, S. (2025). *Analisis Sentimen Ulasan Google Play Store : Studi Komparatif Algoritma SVM , Naïve Bayes , dan Logistic Regression*. 15(3), 610–620.
- Puji Astuti, A., Alam, S., & Jaelani, I. (2022). Komparasi Algoritma Support Vector Machine dengan Naive Bayes Untuk Analisis Sentimen Pada Aplikasi BRImo. *Jurnal Bangkit Indonesia*, 11(2), 1–6.
<https://doi.org/10.52771/bangkitindonesia.v11i2.196>
- Ramadhani, M., & Mubarak, N. (2025). *Pendekatan Machine Learning untuk Analisis Sentimen Ulasan Capcut : Studi Komparatif Svm dan Naive Bayes*. 4(1).
- Syahrul Fahmi. (2024). *Perbandingan Algoritma Naive Bayes, Random Forest, dan Support Vector Machine pada Analisis Sentimen Ulasan Aplikasi Sekolah.mu.pdf*.
- Tempo. (2025). *Selain TikTok, ByteDance Siapkan CapCut Khusus untuk AS | tempo.co*. <https://www.tempo.co/digital/selain-tiktok-bytedance-siapkan-capcut-khusus-untuk-as-1948211>
- Wulandari, M. A. (2025). *Sentimen ulasan pengguna aplikasi capcut terhadap performa render video dengan metode naive bayes*. 6(2).